

НАЦИОНАЛЬНЫЙ ИССЛЕДОВАТЕЛЬСКИЙ УНИВЕРСИТЕТ ИТМО
Факультет ПИиКТ

Нейроинформатика
Лабораторная работа № 1

Выполнил студент
Набокова Алиса Владиславовна
Группа № 3320
Преподаватель: Русак Алена Викторовна

г. Санкт-Петербург

2025

Задание:

I. Провести экспериментальные исследования с гиперпараметрами модели нейронной сети, чтобы получить наилучший результат на тестовом наборе данных.

1. Попробуйте использовать разное количество нейронов на входном слое: 400, 600, 800, 1200.
2. Добавьте в нейронную сеть скрытый слой с разным количеством нейронов: 200, 300, 400, 600, 800.
3. Добавьте несколько скрытых слоев в сеть с разным количеством нейронов в каждом слое.
3. Используйте разное количество эпох: 10, 15, 20, 25, 30.
4. Используйте разные размеры мини-выборки (`batch_size`): 10, 50, 100, 200, 500.
5. Также можно провести эксперименты с подбором скорости обучения (`learning rate`) и с различными оптимизаторами (RMSprop, SGD).

При проведении экспериментов необходимо следить за возможным переобучением.

Batch size

Посмотрим как `batch size` влияет на обучение при разном размере модели


Нейроны во входном слое: 400


Нейронов в скрытом слое: 200

Оптимизатор: Adam

Кол-во эпох: 10

batch size: 10-50-100-200-500






Нейроны во входном слое: 600


Нейронов в скрытом слое: 300

Оптимизатор: Adam

Кол-во эпох: 10

batch size: 10-50-100-200-500






Нейроны во входном слое: 800


Нейронов в скрытом слое: 400

Оптимизатор: Adam

Кол-во эпох: 10

batch size: 10-50-100-200-500






Нейроны во входном слое: 1200

Нейронов в скрытом слое: 600

Оптимизатор: Adam

Кол-во эпох: 10

batch size: 10-50-100-200-500



Ошибка ('loss') на тестовой выборке

Нейроны/Батчи	10	50	100	200	500
400-200	0.4124	0.3447	0.3311	0.3454	0.3416
600-300	0.3965	0.3696	0.3290	0.3502	0.3473
800-400	0.3795	0.3591	0.3353	0.3460	0.3318
1200-600	0.3687	0.3445	0.3607	0.3478	0.3427

Точность ('accuracy') на тестовой выборке

Нейроны/Батчи	10	50	100	200	500
400-200	87.6600%	88.4000%	88.1100%	88.3100%	87.5400%
600-300	88.0600%	87.6000%	88.6100%	88.0900%	87.7800%
800-400	87.7100%	88.2500%	88.8000%	88.7000%	88.5500%
1200-600	88.0200%	88.5300%	87.8300%	88.4400%	88.0100%

Вывод:

- Малый batch size (10)

Градиенты считаются шумно - каждый batch даёт “шумное” приближение к реальному градиенту. Этот шум работает как случайная регуляризация -> модель не переобучается слишком быстро и в целом обучение проходит дольше

- Большой batch size (50, 100, 200)

Градиенты точнее и “гладкие”. Модель быстрее и точнее подгоняется под тренировочные данные -> loss падает быстрее, но обобщение (val_loss) ухудшается, потому что исчезает регуляризирующий шум и происходит переобучение

Остановимся на среднем количестве batch size (100) и проверим влияние эпох на обучение

Эпохи


Нейроны во входном слое: 400


Нейронов в скрытом слое: 200

Оптимизатор: Adam

batch size: 100

Эпохи: 10-15-20-25-30






Нейроны во входном слое: 600


Нейронов в скрытом слое: 300

Оптимизатор: Adam

batch size: 100

Эпохи: 10-15-20-25-30






Нейроны во входном слое: 800


Нейронов в скрытом слое: 400

Оптимизатор: Adam

batch size: 100


Эпохи: 10-15-20-25-30






Нейроны во входном слое: 1200
Нейронов в скрытом слое: 600
Оптимизатор: Adam
batch size: 100

Эпохи: 10-15-20-25-30





Ошибка ('loss') на тестовой выборке

Нейроны/Эпохи	10	15	20	25	30
400-200	0.3549	0.3417	0.3801	0.4101	0.4528
600-300	0.3600	0.3622	0.3845	0.4068	0.4578
800-400	0.3443	0.3564	0.4372	0.4438	0.4554

1200-600	0.3620	0.3661	0.4128	0.4304	0.5148
----------	--------	--------	--------	--------	--------

Точность ('accuracy') на тестовой выборке

Нейроны/Эпохи	10	15	20	25	30
400-200	88.2900%	88.5900%	89.2300%	88.8300%	89.0100%
600-300	88.1300%	89.3000%	88.8800%	89.1200%	89.5900%
800-400	88.1600%	88.5900%	88.4100%	88.8600%	89.0400%
1200-600	88.4600%	89.0000%	89.4100%	88.8800%	88.5200%

Вывод:

Когда эпох мало (10-15) модель успевает только изучить общие закономерности. Ошибка на обучении ещё высокая, но и на валидации примерно такая же -> модель еще не переобучилась

Когда эпох становится слишком много (25-30) модель начинает запоминать тренировочные данные. loss продолжает снижаться -> модель идеально предсказывает обучающие примеры, но на валидации и тесте она начинает хуже работать, потому что уже не видит новых закономерностей, а подгоняет веса под "шум" и частные случаи обучающей выборки

Остановимся на 15 эпохах

Оптимизаторы

Исследуем степень обучения при разных оптимизаторах и объемах модели



Нейроны во входном слое: 400

Нейронов в скрытом слое: 200



эпохи: 15

batch size: 100



SGD



RMSprop



Adam





Нейроны во входном слое: 600

Нейронов в скрытом слое: 300



эпохи: 15

batch size: 100



SGD



RMSprop



Adam





Нейроны во входном слое: 800



Нейронов в скрытом слое: 400

эпохи: 15
batch size: 100



SGD



RMSprop





Adam





Нейроны во входном слое: 1200
Нейронов в скрытом слое: 600
эпохи: 15
batch size: 100



SGD



RMSprop



Adam



Ошибка ('loss') на тестовой выборке

Нейроны/Оптимизаторы	SGD	RMSprop	Adam
400-200	0.4240	0.4169	0.3621
600-300	0.4157	0.3929	0.3477
800-400	0.4262	0.4008	0.3440

1200-600	0.4052	0.4046	0.3569
----------	--------	--------	--------

Точность ('accuracy') на тестовой выборке

Нейроны/Оптимизаторы	SGD	RMSprop	Adam
400-200	85.0900%	87.6200%	88.7800%
600-300	85.2500%	88.2400%	88.9700%
800-400	84.6900%	88.7400%	89.1700%
1200-600	85.7400%	88.6100%	89.0700%

Вывод:

наиболее оптимальным оптимизатор оказался SGD тк он использует "чистый" стохастический градиент без адаптации шага, RMSprop и Adam имеют механизм адаптивного шага, где для "редких" признаков они увеличивают шаг, а для "частых" уменьшают. На малых объемах данных эти адаптивные колебания шага вызывают скачки в направлении градиента, что приводит к "запрыгиванию" в локальные минимумы и резкие скачки val_loss. В результате loss падает быстро (модель выучивает тренировочные данные), но val_loss застревает или даже растёт - переобучение

Проверим влияние learning rate на обучение:

Learning rate

Нейроны во входном слое: 400


Нейронов в скрытом слое: 200


эпохи: 15

batch size: 100

Оптимизатор: SGD

learning rate: 0.0001-0.001-0.01-0.05-0.1





Нейроны во входном слое: 600


Нейронов в скрытом слое: 300


эпохи: 15

batch size: 100

Оптимизатор: SGD

learning rate: 0.0001-0.001-0.01-0.05-0.1





Нейроны во входном слое: 800


Нейронов в скрытом слое: 400

эпохи: 15

batch size: 100

Оптимизатор: SGD

learning rate: 0.0001-0.001-0.01-0.05-0.1



Нейроны во входном слое: 1200


Нейронов в скрытом слое: 600


эпохи: 15

batch size: 100

Оптимизатор: SGD

learning rate: 0.0001-0.001-0.01-0.05-0.1





Ошибка ('loss') на тестовой выборке

Нейроны/lr	0.0001	0.001	0.01	0.05	0.1
400-200	1.3675	0.6240	0.4198	0.3514	0.3254
600-300	1.2887	0.6063	0.4276	0.3346	0.3459
800-400	1.2711	0.6084	0.4168	0.3562	0.3290
1200-600	1.2379	0.5975	0.4236	0.3299	0.3494

Точность ('accuracy') на тестовой выборке

Нейроны/lr	0.0001	0.001	0.01	0.05	0.1
400-200	66.18%	79.26%	84.99%	87.51%	88.50%
600-300	65.96%	80.08%	84.84%	87.88%	87.87%
800-400	65.14%	80.14%	85.30%	86.78%	88.22%
1200-600	67.55%	80.32%	85.30%	87.97%	87.72%

Вывод: При слишком малом lr (0.0001-0.001) обучение идет очень медленно - loss снижается постепенно, accuracy растёт медленно, и модель может не достичь необходимого уровня обучения за заданное число эпох.

При слишком большом lr (0.05-0.01) веса обновляются слишком резко - loss колеблется, возможны скачки или рост ошибки.

Оптимальный $lr=0.01$, где loss плавно уменьшается, а accuracy стабильно растет без переобучения

Проверим влияние количества скрытых слоев и нейронов в них на обучение:


Слои и нейроны


эпохи: 15

batch size: 100

оптимизатор: SGD ($lr=0.01$)

Кол-во скрытых слоев: 2





Ошибка ('loss') на тестовой выборке

Нейроны (входной слой-скрытый слой-скрытый слой)

400-200-200	800-400-400	1200-800-800	400-800-800	600-800-200	600-200-800
0.4107	0.3894	0.3892	0.4175	0.3944	0.4020

Точность ('accuracy') на тестовой выборке

Нейроны (входной слой-скрытый слой-скрытый слой)


400-200-200	800-400-400	1200-800-800	400-800-800	600-800-200	600-200-800
85.21%	86.16%	86.12%	85.43%	85.96%	85.91%


эпохи: 15

batch size: 100

оптимизатор: SGD(lr=0.01)

Кол-во скрытых слоев: 3





Ошибка ('loss') на тестовой выборке

Нейроны (входной слой-скрытый слой-скрытый слой-скрытый слой)

400-200-200	600-400-400	1200-800-800	400-800-800	600-800-400-200	600-200-400-800	600-600-400-200
-------------	-------------	--------------	-------------	-----------------	-----------------	-----------------

0.3893	0.3991	0.3782	0.3960	0.3871	0.4013	0.3917
--------	--------	--------	--------	--------	--------	--------

Точность ('accuracy') на тестовой выборке

Нейроны (входной слой-скрытый слой-скрытый слой-скрытый слой)						
400-200-200-200	600-400-400-400	1200-800-800-800	400-800-800-800	600-800-400-200	600-200-400-800	600-600-400-200
86.13%	85.63%	86.63%	85.84%	86.32%	85.57%	86.14%

Вывод: Обучение с убывающим количеством нейронов в слоях показало наиболее прогрессивные результаты. Такая архитектура позволяет сети сжимать информацию и отбрасывать лишние детали. Она работает как встроенная регуляризация - веса не могут хранить все частные особенности обучающей выборки. В итоге точность на тесте близка к точности на валидации, что означает хорошее обобщение.

У больших моделей с максимальным числом нейронов очень большая емкость и много параметров. Ей проще "подогнать" данные и компенсировать колебания градиентов. При этом она показывает незначительные отличия в сравнении с более компактными моделями

При восходящем количестве нейронов модели наоборот приходится восстанавливать потерянную информацию, что приводит к неустойчивости и переобучению

Увеличение количества слоев повышает точность обучения, тк сеть получает больше параметров и может точнее аппроксимировать данные. При этом возрастает риск переобучения - точность на тестовых и валидационных данных может снижаться, а ошибка расти.

